

AI Quality Audit: O Desafio Gilded Rose

1. Contextualização e Motivação

A indústria de desenvolvimento de software vive uma mudança de paradigma. Com a popularização das IAs Generativas (LLMs), a barreira para *escrever* código diminuiu drasticamente. No entanto, a facilidade de geração trouxe um novo risco: a inserção massiva de códigos plausíveis, mas sutilmente incorretos, frágeis ou com débitos técnicos ocultos.

Neste cenário, o papel do profissional de Teste e Qualidade evolui. Vocês deixam de ser apenas "escritores de scripts de teste" para se tornarem **Audidores de Qualidade e Engenheiros de Prompt**. O mercado atual não premia quem sabe copiar código do ChatGPT, mas sim quem sabe **guiar a IA** para produzir resultados robustos e, crucialmente, quem possui o conhecimento técnico para validar se a máquina está "alucinando" ou entregando qualidade real.

2. Objetivos de Aprendizagem

Esta atividade foi desenhada para consolidar as competências críticas do semestre em um cenário realista de 2025:

1. **Engenharia de Prompt para Testes:** Aprender a formular pedidos técnicos precisos para extrair o melhor das LLMs.
2. **Auditoria de Código (Code Review):** Desenvolver o olhar crítico para identificar *Test Smells* e falsas sensações de segurança em códigos gerados automaticamente.
3. **Uso de Métricas Avançadas:** Aplicar Teste de Mutação e Análise Estática como ferramentas de "prova real" contra a IA.
4. **Capacidade de Síntese:** Comunicar achados técnicos complexos de forma visual e direta (soft skill essencial).

3. Descrição da Missão: "O Auditor vs. A Máquina"

O grupo assumirá a responsabilidade de modernizar o famoso código legado "**Gilded Rose**", conhecido mundialmente por sua lógica de negócios complexa e estrutura condicional confusa. Porém, vocês não farão o trabalho braçal; vocês coordenarão uma IA para fazê-lo.

O trabalho consiste em orquestrar uma IA para testar e refatorar este código e, em seguida, realizar uma **autópsia técnica** do resultado. Vocês devem questionar: *"A IA cobriu todos os cenários de borda? A refatoração manteve o comportamento original? Os testes gerados são robustos ou quebram com qualquer mudança (frágeis)?"*.

- **Repositório Base:** <https://github.com/emilybache/GildedRose-Refactoring-Kata>

3.1. A Regra da Exclusividade (Stack Tecnológica)

Para enriquecer a discussão em sala, cada grupo deverá operar com uma configuração única. Vocês devem escolher uma combinação de **Linguagem de Programação + LLM**.

- *Exemplo:* Se o Grupo A escolheu Java + ChatGPT, o Grupo B deve buscar outra combinação, como Java + DeepSeek ou Python + ChatGPT.
- **Ação:** Registrem sua escolha imediatamente no Fórum do Canvas. A alocação segue a ordem de chegada (*First-come, first-served*).

Sugestões de LLMs Gratuitas (Para inspiração):

- **ChatGPT (OpenAI):** Versão 3.5 ou 4o-mini (Gratuitas).
- **Gemini (Google):** Excelente integração e contexto.
- **DeepSeek (DeepSeek-V3/R1):** Modelo *open-weight* muito forte em código.
- **Claude 3.5 Sonnet (Anthropic):** Via interface web (limite diário gratuito), conhecido por gerar código muito limpo.
- **Microsoft Copilot:** Usa GPT-4 no backend gratuitamente.
- **HuggingChat / Llama 3:** Alternativas Open Source.

4. Roteiro de Execução

Fase 1: Engenharia de Prompt e Geração

Utilizando o repositório do *Gilded Rose Refactoring Kata* (Emily Bache) como base, vocês deverão iterar com a IA escolhida. O objetivo aqui é explorar diferentes formas de pedir (prompts):

- Solicitem a criação de uma suíte de testes unitários que garanta 100% de cobertura.
- Solicitem a refatoração do código para padrões de projeto mais limpos (*Clean Code*).
- Gerar cenários de BDD.
- *Ponto de Atenção:* Salvem os prompts utilizados. Vocês precisarão demonstrar no vídeo se usaram técnicas como "Chain-of-Thought", "Persona Pattern" ou se apenas colaram o código.

Fase 2: A Auditoria de Qualidade (O Coração do Trabalho)

É aqui que a nota é definida. Com o código gerado pela IA em mãos, vocês devem agir como "Advogados do Diabo" utilizando o ferramental da disciplina:

- **Verificação de Cobertura:** A IA prometeu 100%? Ferramentas como JaCoCo ou Istanbul confirmam isso? Existem caminhos lógicos não testados?
 - **Teste de Mutação (A Prova de Fogo):** Executem uma ferramenta de mutação (Pitest, Stryker, etc.). Os testes da IA matam os mutantes ou eles sobrevivem? Se sobrevivem, o teste da IA é fraco.
 - **Análise de Smells:** A IA gerou asserções genéricas? Código duplicado nos testes? Identifiquem os *test smells*.
-

5. O Entregável: Vídeo-Demonstração

A entrega será um **vídeo técnico narrado**, hospedado no YouTube, Drive ou .mp4.

O vídeo deve ser uma narrativa fluida, mostrando a tela e explicando o processo. **O que é obrigatório conter:**

1. **Setup:** Apresentação rápida do grupo e da combinação (Linguagem + LLM).
2. **Revelação dos Prompts:** Mostrem *como* vocês pediram. O prompt fez diferença no resultado?
3. **Evidências Visuais:** Não apenas falem; mostrem os relatórios de Cobertura e Mutação na tela. Deem zoom nos números vermelhos e verdes.
4. **O Veredito (Análise Crítica):** Concluam com uma análise honesta. A IA passou na auditoria? Onde vocês tiveram que intervir manualmente? O código ficou realmente melhor ou apenas diferente?

6. Dinâmica da Aula Final: Avaliação de Pares

A entrega do vídeo é apenas a primeira parte. A aula final funcionará como um painel técnico de revisão.

- **Sorteio:** Vídeos aleatórios serão exibidos para a turma.
- **Log de Crítica (Atividade em Sala):** Todos os alunos deverão preencher um **Log de Avaliação** individual durante as apresentações. Vocês deverão sintetizar os pontos fortes e fracos das abordagens dos colegas (ex: "O Grupo X usou um prompt muito criativo, mas a ferramenta de mutação mostrou falhas").
- **Nota:** A entrega deste Log será ao final da aula. A presença e a atenção ativa são obrigatórias.

7. Critérios de Avaliação (Total: 10 Pontos)

Critério	Peso	Descrição do Esperado
Evidência Técnica e Prompts	4,0	O vídeo demonstra visualmente a execução dos testes, os relatórios de métricas (Cobertura/Mutação) e, crucialmente, exibe os Prompts utilizados para gerar o código.
Profundidade da Análise (Audit)	3,0	Capacidade do grupo de criticar a IA. O grupo identificou onde a IA falhou? A discussão sobre Test Smells e fragilidade dos testes foi embasada tecnicamente?
Log de Crítica (Individual)	3,0	Qualidade do resumo e das observações feitas sobre os trabalhos dos colegas no Log entregue em sala de aula.